

Relatório Classificação de Tipos de Pokémon Utilizando Support Vector Machines (SVM)

Nome: Danilo dos Santos Lopes	RGM: 11241101111
Nome: Fernando Gabriel Arakawa de Souza	RGM: 11261401804
Nome: Gabriel Souza Silva	RGM: 11241101483
Nome: Luiz Fernando Carrupt Macera	RGM: 11261401796
Nome: Vinicius Baptista Amaral Monteiro	RGM: 11241104123

Professor: Fabiano Bezerra Menegidio. **Universidade de Mogi das Cruzes**
Data:01/10/2026 **Salas:** 6A e 6D **Matéria:** Inteligência Artificial **Matutino**

Introdução

O aprendizado de máquina desempenha um papel fundamental em mapear e categorizar as entidades complexas com base em vetores de atributos contínuos, assim o contexto da análise quantitativa de dados de combate em cada Pokémon, incluindo métricas numéricas totalmente estruturada como HP, Attack, Defense, Special Defense Speed e entre outros atributos gerais.

A aplicação de algoritmos preditivos permite transformar variáveis contínuas brutas extraídas de uma Pokédex em inferências categóricas sobre a tipagem primária da entidade. Essa abordagem válida o uso de padrões estatísticos subjacentes para a determinação automática de classes operacionais.

O desafio envolve em classificar multi-classe de 18 tipagens de Pokémon utilizando exclusivamente as suas estatísticas numéricas de base e a sobreposição das atribuições de atributos entre diferentes tipos dificulta a separação por hiperplanos em espaços multidimensionais, tendo a necessidade de uma estratégia de trabalhar com apenas um tipo de pokémon para tratar rigorosamente os dados.

Objetivos

As grandes metas estabelecidas pelo nosso grupo para essa biblioteca do Pokémon seria:

- Realizar o mapeamento numérico sequencial das 18 tipagens primárias originais (type_1).
- Fazer a divisão sistemática do conjunto total das tipagens em 3 grupos isolados, contendo 6 tipos cada, tendo que maximizar o desempenho e a estabilidade da máquina de aprendizado.
- Conduzir uma avaliação comparativa rigorosa da acurácia global e dos métricas por classe (Precision, Recall, F1-Score e Support) entre os três subgrupos estabelecidos.

A estrutura de mapeamento realizada para os subgrupos encontra-se na tabela a seguir:

Grupo	Tipos Mapeados (Código e Nome)
Grupo 1	1: bug, 2: dark, 3: dragon, 4: electric, 5: fairy, 6: fighting
Grupo 2	7: fire, 8: flying, 9: ghost, 10: grass, 11: ground, 12: ice
Grupo 3	13: normal, 14: poison, 15: psychic, 16: rock, 17: steel, 18: water

Metodologia

Este projeto utiliza Machine Learning para resolver um problema de classificação multiclasse, com o objetivo de prever o tipo de um Pokémon com base exclusivamente em seus atributos de combate. Como os algoritmos matemáticos processam apenas números e não compreendem textos ou imagens, a metodologia se inicia com uma limpeza rigorosa dos dados. Todas as colunas textuais ou irrelevantes para o desempenho em batalha, como nome, cor, habitat e taxa de crescimento, são removidos.

Em seguida, os nomes dos dezoito tipos de Pokémons são convertidos em números, criando uma base de dados estritamente matemáticas formada por estatísticas vitais como HP, ataque, defesa e velocidade.

A principal e mais inteligente estratégia adotada na sua abordagem é a técnica de dividir para conquistar. Tentar ensinar o computador a classificar dezoito categorias simultaneamente gera muita sobreposição e confusão, pois os atributos de um Pokémon de água podem ser matematicamente muito semelhantes aos de um Pokémon de gelo. Para contornar esse obstáculo, os tipos foram divididos em três

grupos menores, contendo seis tipos cada um. Isso simplifica o ambiente de decisão do algoritmo, permitindo que ele encontre fronteiras e padrões muito mais claros dentro de cada subgrupo.

Resultados

A avaliação demonstra uma variação considerável no desempenho preditivo entre o Grupo A, Grupo B e Grupo C, tendo evidências de composições dos tipos e o volume de amostras afetam diretamente a capacidade do algoritmo SVM em estabelecer hiperplanos decisórios precisos.

Desempenho do Grupo 1 (Acurácia Global: 63%)

O Grupo 1 obteve acurácia de 59% e precisão média ponderada de 63% sobre um suporte total de n=59 amostras de teste. A otimização via GridSearchCV definiu o modelo ideal com kernel RBF (C=100, gamma=0.01) e pesos balanceados. A classe Fairy (Tipo 5) destacou-se com 80% de precisão, 50% de recall e F1-score de 62% em 8 amostras de teste. A classe Electric (Tipo 4) registrou o maior F1-score do subconjunto, alcançando 70% com precisão de 73%.

Melhores parâmetros encontrados: {'C': 100, 'gamma': 0.01, 'kernel': 'rbf'}				
	precision	recall	f1-score	support
1	0.44	0.80	0.57	10
2	0.50	0.42	0.45	12
3	0.60	0.67	0.63	9
4	0.73	0.67	0.70	12
5	0.80	0.50	0.62	8
6	0.80	0.50	0.62	8
accuracy			0.59	59
macro avg	0.65	0.59	0.60	59
weighted avg	0.63	0.59	0.59	59

Os pokémon no Grupo 1 são desses tipos: 1 – Bug, 2 – Dark, 3 – Dragon, 4 – Electric, 5 – Fairy e 6 –Fighting.

Desempenho do Grupo 2 (Acurácia Global: 44%)

O Grupo 2 apresentou a menor eficiência preditiva, com acurácia global de 42% e precisão média ponderada de 50% sobre um suporte total de n=57 amostras de teste. A otimização via GridSearchCV definiu o modelo ideal com kernel linear (C=0.1, gamma='scale') e pesos balanceados. O tipo Ground (Tipo 11) foi o destaque positivo do grupo, registrando 71% de precisão, 45% de recall e F1-score de 56% em 11 amostras. A classe Flying (Tipo 8) sofreu colapso preditivo total devido ao suporte extremamente reduzido (n=2), obtendo métricas nulas de precisão e recall.

```
Melhores parâmetros encontrados (Grupo 2): {'C': 0.1, 'gamma': 'scale', 'kernel': 'linear'}
precision    recall  f1-score   support

    7         0.50      0.67      0.57         12
    8         0.00      0.00      0.00          2
    9         0.20      0.20      0.20         10
   10         0.60      0.32      0.41         19
   11         0.71      0.45      0.56         11
   12         0.43      1.00      0.60          3

 accuracy          0.42         57
 macro avg         0.41      0.44      0.39         57
 weighted avg         0.50      0.42      0.43         57
```

Os pokémon no Grupo 1 são desses tipos: 7 – Fire, 8 – Flying, 9 – Ghost, 4 – Grass, 5 – Ground e 6 – Ice.

Desempenho do Grupo 3 (Acurácia Global: 54%)

O Grupo 3 registrou uma acurácia global de 38% e precisão média ponderada de 39% sobre um suporte total de n=90 amostras de teste. A otimização via GridSearchCV definiu o modelo ideal com kernel RBF (C=10, gamma=0.1) e pesos balanceados. A classe Psychic (Tipo 15) obteve o melhor desempenho do grupo, com 67% de precisão, 57% de recall e F1-score de 62% em 14 amostras. O tipo Water (Tipo 18), apesar do maior suporte do subconjunto (n=28), apresentou desempenho moderado com 40% de precisão e F1-score de 38%.

```
Melhores parâmetros encontrados (Grupo 3): {'C': 10, 'gamma': 0.1, 'kernel': 'rbf'}
```

	precision	recall	f1-score	support
13	0.44	0.52	0.48	23
14	0.18	0.18	0.18	11
15	0.67	0.57	0.62	14
16	0.09	0.17	0.12	6
17	0.25	0.12	0.17	8
18	0.40	0.36	0.38	28
accuracy			0.38	90
macro avg	0.34	0.32	0.32	90
weighted avg	0.39	0.38	0.38	90

Os pokémon no Grupo 1 são desses tipos: 13 – Normal, 14 – Poison, 15 – Psychic, 16 – Rock, 17 – Steel e 18– Water.

Matriz de Confusão

A matriz de confusão será utilizada para avaliar o desempenho do modelo SVM na classificação dos Pokémon. Ela permite comparar as classes reais dos Pokémon com as classes previstas pelo modelo, possibilitando identificar tanto as classificações corretas.

Para este experimento, serão analisadas três matrizes de confusão, correspondentes aos três grupos definidos na metodologia. O Grupo 1 é composto pelos tipos Bug, Dark, Dragon, Electric, Fairy e Fighting; o Grupo 2 pelos tipos Fire, Flying, Ghost, Grass, Ground e Ice; e o Grupo 3 pelos tipos Normal, Poison, Psychic, Rock, Steel e Water. Relatório DataSet Pokémon

Na matriz, os valores da diagonal principal representam os Pokémon classificados corretamente no modelo, enquanto os valores fora da diagonal representam casos em que o modelo confundiu um tipo com outro. Dessa forma, a matriz permite identificar quais classes apresentam maior dificuldade de classificação.

A utilização dessa análise é importante porque os resultados obtidos demonstraram diferenças de desempenho entre os grupos. O Grupo 1 apresentou 59% de acurácia, o Grupo 2 apresentou 42% e o Grupo 3 apresentou 38%. Relatório DataSet Pokémon

No Grupo 2, por exemplo, o tipo Flying apresentou desempenho nulo, principalmente devido ao seu baixo número de amostras de teste, enquanto o tipo Ground apresentou melhor desempenho individual. Já no Grupo 3, o tipo Psychic apresentou a maior precisão individual, com 0,90. Relatório DataSet Pokémon

Portanto, a matriz de confusão complementa as métricas de acurácia, precisão, recall e F1-score, permitindo visualizar de maneira mais detalhada os padrões de acerto e erro do modelo SVM.

Discussão

A análise do desempenho dos modelos baseados em Support Vector Machine revela aspectos cruciais sobre a viabilidade de classificar a tipagem primária de Pokémon utilizando exclusivamente seus atributos de combate. As taxas de acurácia obtidas, variando entre 38% e 59% nos diferentes grupos, refletem a complexidade inerente ao problema. Dentro do jogo, as estatísticas base tais como HP, Ataque, Defesa, Ataque Especial, Defesa Especial e Velocidade são projetadas primariamente para o balanceamento das batalhas e não para funcionarem como assinaturas estatísticas exclusivas. Dessa forma, é natural que ocorra uma sobreposição significativa entre diferentes classes, especialmente entre tipos com funções táticas semelhantes, como os atacantes físicos.

A aplicação da estratégia de divisão do problema em três grupos menores mostrou-se conceitualmente vantajosa para mitigar a sobreposição de dezoito categorias simultâneas. No entanto, a análise individual dos subgrupos expõe comportamentos distintos. No Grupo 1, destaca-se o excelente desempenho na identificação do tipo Fada, que alcançou um F1-score de 0,88 graças à sua distribuição de atributos, caracterizada por elevada Defesa Especial e Ataque Especial combinados com baixo Ataque Físico. Em contrapartida, tipos focados no combate físico, como Lutador e Noturno, apresentaram maior taxa de erro devido à similaridade de suas estatísticas com outros Pokémon ofensivos do mesmo grupo.

Conclusão

Conclui-se que a utilização de um algoritmo SVM para classificar a tipagem primária dos Pokémons ressaltou o quão viável a modelagem preditiva pode ser na prática, entretanto também evidenciou os limites gerados quando os atributos numéricos se sobrepõem em espaços multidimensionais. Um grande acerto de fato foi a realização da divisão dos 18 tipos de Pokémon originais em 3 grupos isolados com 6 desses tipos em cada, pois essa técnica aliada a implementação do gridSearchCV simplificou o espaço de decisão e reduziu a confusão entre as categorias, possibilitando assim que o modelo apresentasse diferentes níveis de acurácia em cada modelo de teste e realizando diversas simulações com parâmetros diferentes até encontrar os mais adequados.

Ajustado por pesos de classe balanceados, o grupo 1 obteve a maior taxa de acerto, chegando a 59% de acurácia global (utilizando os hiperparâmetros $C=100$, $\gamma=0.01$ e o kernel RBF) e com destaque para os Pokémons tipo Fada que obtiveram incríveis 80% em precisão e revogação de 0,62, obtendo também valores mais altos de revogação para o tipo Inseto (80%) e para o tipo Elétrico (67%). O vetor desse destaque pode ser observado devido aos seus altos valores de defesa e ataque especial, tendo como contrapartida um baixo valor de ataque físico para os Pokémons tipo Fada.

Por sua vez, o Grupo 2 registrou uma eficiência preditiva moderada comparada aos outros dois grupos, atingindo 42% (ajustados pelos parâmetros $C=0.1$, $\gamma='scale'$ e kernel linear). O kernel linear mostrou ser a melhor alternativa buscando corrigir através de hiperplanos simples o overfitting encontrado, entretanto esse viés causou uma falha total na predição dos Pokémons do tipo Voador que pelo baixo número de suas amostras teve sua precisão e revogação zerados. Do contrário, Pokémons do tipo Gelo obtiveram 100% de revogação e 43% de precisão enquanto o tipo Terrestre se destacou alcançando 71% de precisão.

O grupo 3 foi o resultante do menor desempenho registrando 38% de acurácia global (seguindo os parâmetros $C=10$, $\gamma=0.1$ e com o kernel RBF). O tipo Psíquico manteve a maior precisão dentro do grupo atingindo a marca de 67% de acertos atribuídos em suas características de velocidade e ataque especial. Porém os Pokémons do tipo Água agiram como um atrator preditivo forte, pois possuindo a maior parte das amostras acabou gerando uma dispersão de suas predições nas classes correlatas.

Isso confirma que as estatísticas de combate foram criadas para ajustar a dinâmica do jogo, e não para servirem como identificadores exclusivos. A combinação de perfis táticos semelhantes entre tipos e a falta dos tipos secundários nas variáveis de entrada implementam sobreposições complexas no espaço de atributos, resistentes até mesmo a transformações por kernels não lineares. Para mitigar parte do viés identificado, as primeiras soluções serão a inclusão do tipo secundário dos Pokémons e ajustar o desbalanceamento dos dados, pois esses reparos reduzirão consideravelmente o ruído. Ao adicionar o tipo secundário por meio de uma nova variável (Tipo_2) impede-se que os atributos numéricos possam contaminar o espaço de decisão comprometendo assim a definição do hiperplano e garantindo que o algoritmo interprete corretamente perfis híbridos, e ajustando a quantidade e/ou a distribuição dos dados impede-se que classes raras sejam anuladas em decorrência da grande atração exercida pelas classes mais populosas.